

Analisi empirica di Transformer per Graph Connectivity

Confronto con *Transformers Provably Learn Algorithmic Solutions for Graph Connectivity, But Only with the Right Data*

Introduzione

In questo breve report presentiamo una serie di esperimenti svolti sulla repository implementata per il task di *graph connectivity*, con l'obiettivo di verificare quanto i risultati empirici ottenuti con Transformer standard siano coerenti con le conclusioni del paper *Transformers Provably Learn Algorithmic Solutions for Graph Connectivity, But Only with the Right Data*.

Il task consiste nel predire la matrice di connettività di un grafo a partire dalla matrice di adiacenza con self-loop. L'idea centrale del paper è che un Transformer di profondità L può imparare una soluzione realmente algoritmica solo quando la distribuzione di training contiene abbastanza grafi *within-capacity*, cioè con diametro non superiore a 3^L . In caso contrario, il modello tende a imparare euristiche locali o statistiche aggregate che aiutano in-distribution ma non generalizzano in modo esatto fuori distribuzione.

Nei nostri esperimenti abbiamo considerato principalmente un **Transformer standard a 2 layer** con:

$$n = 20, \quad d_{\text{model}} = 128, \quad n_{\text{heads}} = 4, \quad d_{ff} = 256, \quad \text{dropout} = 0,$$

addestrato su grafi Erdős–Rényi $\text{ER}(20, p)$, con diverse varianti della distribuzione di training.

1. Baseline

Setup

Architettura usata:

- Transformer standard, 2 layer
- $n = 20, p = 0.08$
- $d_{\text{model}} = 128, 4 \text{ heads}, d_{ff} = 256$
- batch size = 64, 20 epoche
- training su $\text{ER}(20, 0.08)$ senza restrizioni sul diametro




Figura 1: Baseline: andamento di exact-match e pairwise accuracy su validation ER e su test OOD (TwoChains e TwoCliques).




Figura 2: Baseline: accuratezza condizionata sulla distanza del cammino.

Mini analisi. Il risultato di baseline è coerente con l’ipotesi che il modello stia imparando soprattutto una *euristica pairwise* e non una vera soluzione algoritmica della connettività. Nel grafico di training history si vede infatti che:

- su validation ER il modello migliora molto;
- su OOD l’exact-match resta essenzialmente nullo;
- la pairwise accuracy è invece significativamente sopra il caso casuale.

Questo *non* è il pattern mostrato nel paper, e i nostri grafici lo rendono evidente. Nel paper, la capacità empirica dei Transformer standard è descritta come molto netta: per coppie con distanza $d_G(u, v) \leq 3^L$ le predizioni sono quasi perfette, mentre oltre soglia decadono rapidamente. Nei nostri risultati, invece, la pairwise accuracy rimane alta anche per distanze ben superiori a $3^L = 9$, e addirittura torna a 1.0 sulle distanze più grandi osservate. Questo significa che il modello non sta mostrando una vera “capacity wall” come nel paper, ma piuttosto un comportamento fortemente dipendente dalla distribuzione del dataset ER. Probabilmente le coppie di nodi con quella grande distanza sono poche, strutturalmente facili, o statisticamente sbilanciate nel dataset considerato. Quindi bastano poche coppie azzeccate e l’accuracy sale.

2. Capacity test

Setup

Stessa architettura della baseline:

- Transformer standard, 2 layer
- $n = 20$, $p = 0.08$
- $d_{\text{model}} = 128$, 4 heads, $d_{ff} = 256$




Figura 3: Capacity test: massima lunghezza di cammino affidabile durante il training. La linea tratteggiata indica la soglia teorica $3^L = 9$ per $L = 2$.



Figura 4: Nel paper i Transformer standard a 2 layer mostrano una barriera empirica in corrispondenza di 3^L .

Mini analisi. Anche il capacity test, alla luce dei grafici ottenuti, non replica in modo convincente il risultato del paper. Nel paper la Figura 10 mostra una progressione ordinata della massima lunghezza di cammino perfettamente predetta che cresce fino a fermarsi in prossimità di 3^L , confermando il limite teorico di capacità. Nel nostro grafico, invece, la massima lunghezza affidabile oscilla in modo molto irregolare e supera spesso la soglia teorica, arrivando fino a 15. Un andamento del genere è difficilmente compatibile con l'idea di una barriera strutturale netta a 3^L .

Un motivo può essere il fatto che basta che poche coppie lontane risultino facili o statisticamente favorevoli per far salire artificialmente la metrica oltre 3^L . Probabilmente la questione sorge per la differenza di quantità di dati.

3. Restrict diameter dynamics

Setup

Architettura usata:

- Transformer standard, 2 layer
- $n = 20$
- $d_{\text{model}} = 128$, 4 heads, $d_{\text{ff}} = 256$
- training su $\text{ER}(20, p)$ con diverse restrizioni sul diametro: nessuna, ≤ 11 , ≤ 9 , ≤ 7
- valutazione OOD su TwoChains e TwoCliques




Figura 5: Restrict diameter dynamics: exact-match OOD durante il training al variare della restrizione sul diametro.




Figura 6: Nel paper, restringere il diametro porta a una forte crescita dell'exact-match su TwoChains per il Transformer standard.




Figura 7: Nel paper si osserva anche un netto miglioramento su TwoCliques quando il training usa i dati “giusti”.

Mini analisi e discrepanza di scala. Anche in questo punto i nostri risultati divergono nettamente da quanto mostrato nel paper per i Transformer standard. Nel paper, restringere il training ai grafi within-capacity permette al modello di imboccare la soluzione algoritmica e di generalizzare molto meglio su TwoChains e TwoCliques. Nei nostri esperimenti, invece, l’exact-match OOD resta sostanzialmente a zero per tutte le configurazioni.

Tuttavia, un’analisi attenta dei parametri di addestramento svela il motivo di questa discrepanza. Osservando la Figura 7 del paper, la transizione di fase in cui l’exact-match inizia a salire vertiginosamente avviene solo dopo circa **400.000 step**. Gli autori, infatti, addestrano il Transformer per ben 10^6 step con un batch size di 1000, esponendo il modello a 1 miliardo di grafi e utilizzando una dimensione nascosta più ampia ($d_{model} = 512$).

Al contrario, nei nostri esperimenti ci siamo fermati a circa **20.000 step** (o 50 epoche), esplorando solamente la "Fase 1" iniziale dell’addestramento. In questa fase prematura, il modello impara al massimo un miglioramento debole a livello *pairwise*, troppo piccolo e rumoroso per tradursi in una classificazione esatta sull’intera matrice (exact-match). Non c’è quindi un fallimento della teoria, ma semplicemente non abbiamo ancora raggiunto il regime di scala (simile al fenomeno del *grokking*) necessario per far emergere l’algoritmo vero e proprio.

4. Restrict diameter sweep

Setup

Stessa architettura standard a 2 layer, con sweep della probabilità p :

- $p \in [0.05, 0.55]$
- restrizioni sul diametro: nessuna, ≤ 11 , ≤ 9 , ≤ 7
- metrica mostrata: exact-match OOD finale




Figura 8: Restrict diameter sweep: exact-match OOD finale al variare di p e della restrizione sul diametro.

Mini analisi. Il messaggio del grafico è molto netto: **variare p non cambia il quadro qualitativo dell’exact-match**. In tutto lo sweep, l’exact-match su TwoChains e TwoCliques resta praticamente nullo.

Questo suggerisce che il problema non è un singolo valore sfortunato di densità del training set, ma una difficoltà più profonda. L’assenza di improvement in exact-match per tutti i valori di p rafforza l’idea che il collo di bottiglia sia nella dinamica di apprendimento (e nella durata del training), non semplicemente nella scelta della densità.

5. Restrict diameter dynamics pairwise

Setup

Post-processing dei run già addestrati:

- stesso Transformer standard, 2 layer
- valutazione pairwise OOD lungo le 50 epoche
- grafico costruito per $p = 0.2$




Figura 9: Restrict diameter dynamics pairwise: andamento della pairwise accuracy OOD lungo il training, separando TwoChains e TwoCliques.

Mini analisi. Questo è il grafico più informativo tra quelli di restrict diameter. Qui finalmente si vede che *qualcosa* cambia: su TwoChains la pairwise accuracy migliora davvero leggermente quando il training è ristretto a diametri più piccoli, specialmente con $\text{diam} \leq 7$.

Tuttavia il miglioramento resta limitato:

- TwoChains sale solo di pochi punti percentuali rispetto al caso unrestricted;
- TwoCliques resta sostanzialmente a 0.5, cioè al livello casuale;
- l'effetto non si traduce in exact-match.

Questa distinzione è centrale per l'interpretazione dei risultati. Il modello sembra effettivamente imparare una *euristica un po' migliore* sulle coppie di nodi in TwoChains, ma non una procedura esatta di connettività. Se la pairwise accuracy resta intorno a 0.54–0.61, l'exact-match su tutta la matrice resta inevitabilmente vicino a zero.

6. Curriculum diameter dynamics

Setup

Esperimento separato con curriculum sul diametro:

- Transformer standard, 2 layer
- $n = 20$, $p = 0.08$
- 4 modalità: standard, restrict-only, curriculum_1 ($\leq 9 \rightarrow$ unrestricted), curriculum_2 ($\leq 7 \rightarrow \leq 9$)
- training in chunk di 200 step fino a 5000 step




Figura 10: Curriculum diameter dynamics: exact-match OOD durante il training per standard, restrict-only e due curriculum sul diametro.

Mini analisi. Su TwoChains l'exact-match resta zero in tutte le modalità. Su TwoCliques compaiono solo picchi transitori, spesso abbastanza marcati ma instabili, che poi collassano rapidamente.

Quindi il curriculum, almeno in questa forma, non risolve il problema di fondo. Anzi, il fatto che compaiano picchi transitori seguiti da crolli è compatibile con un modello che sta inseguendo scorciatoie sensibili alla distribuzione corrente del training set, non una regola generale.

Conclusione

Nel complesso, i risultati mostrano 3 fatti principali:

1. **La discrepanza apparente è dovuta alla scala di addestramento (Training Horizon).** I risultati del paper rivelano che l'apprendimento dell'algoritmo esatto è simile al fenomeno del *grokking*. Nel paper, l'exact-match inizia a migliorare significativamente solo dopo circa 400.000 step (con un batch size massiccio). I nostri esperimenti, confinati a ~ 20.000 step e con una capacità inferiore ($d_{model} = 128$), catturano solo la dinamica transitoria iniziale (Fase 1), prima che l'euristica venga soppressa.
2. **In questa prima fase, le dinamiche di training mostrano l'uso predominante di euristiche.** Nei nostri esperimenti, restringere il diametro del training set non porta immediatamente il modello a imparare una soluzione esatta di connettività. L'exact-match OOD resta nullo quasi ovunque proprio perché l'algoritmo non è ancora maturato.
3. **Il segnale residuo algoritmico è debole e visibile solo nella pairwise accuracy su TwoChains.** Pur nel regime di sotto-addestramento in cui ci troviamo, si nota un leggero vantaggio predittivo quando i dati sono ristretti in diametro. Tuttavia, nella fase pre-400k step, questo effetto è troppo flebile per far convergere in modo esatto le predizioni sull'intera matrice.